

Approximation gaussienne d'une loi de Poisson

April 14, 2026

0.1 Énoncé du problème

Soit $P_n \sim \text{Poisson}(n)$ une variable aléatoire de paramètre n . On rappelle que :

$$\mathbb{P}(P_n = k) = e^{-n} \frac{n^k}{k!}, \quad \forall k \in \mathbb{N}$$

avec $\mathbb{E}[P_n] = n$ et $\text{Var}(P_n) = n$.

On s'intéresse à la variable centrée-réduite :

$$\bar{P}_n = \frac{P_n - n}{\sqrt{n}}$$

et à l'erreur maximale entre sa fonction de répartition et celle de la loi normale centrée réduite :

$$\alpha_n = \sup_{x \in \mathbb{R}} |\mathbb{P}(\bar{P}_n \leq x) - \Phi(x)|,$$

où Φ est la fonction de répartition de $\mathcal{N}(0, 1)$.

0.2 Réduction de l'intervalle d'étude

On montre qu'on peut se limiter à $x \in [-3, 3]$. Pour cela, on majore les queues de distribution par une inégalité de convexité.

En effet, pour tout x ,

$$|\mathbb{P}(\bar{P}_n \leq x) - \Phi(x)| \leq (1 - \mathbb{P}(\bar{P}_n \leq x)) + (1 - \Phi(x)).$$

Pour tout x ,

$$|\mathbb{P}(\bar{P}_n \leq x) - \Phi(x)| \leq \mathbb{P}(\bar{P}_n > x) + (1 - \Phi(x)).$$

0.2.1 Inégalité par convexité

Pour tout $\theta > 0$, par l'inégalité de Markov appliquée à $e^{\theta P_n}$ (la fonction exponentielle est convexe) :

$$\mathbb{P}(\bar{P}_n > x) = \mathbb{P}(P_n > n + \sqrt{n}x) \leq \frac{\mathbb{E}[e^{\theta P_n}]}{e^{\theta(n + \sqrt{n}x)}}.$$

La fonction génératrice des moments de P_n est :

$$\mathbb{E}[e^{\theta P_n}] = \exp(n(e^\theta - 1)).$$

Ainsi :

$$\mathbb{P}(\bar{P}_n > x) \leq \exp(n(e^\theta - 1) - n\theta - \sqrt{n}\theta x).$$

Posons $\varphi_n(\theta) = n(e^\theta - 1 - \theta) - \sqrt{n}\theta x$. La fonction $\theta \mapsto e^\theta - 1 - \theta$ est convexe (sa dérivée seconde est $e^\theta > 0$), donc φ_n admet un minimum unique.

0.2.2 Calcul du minimum

On annule la dérivée :

$$\varphi'_n(\theta) = n(e^\theta - 1) - \sqrt{n}x = 0 \quad \Rightarrow \quad e^\theta = 1 + \frac{x}{\sqrt{n}}.$$

Par convexité, ce point est le minimum. On obtient :

$$\theta_n(x) = \ln \left(1 + \frac{x}{\sqrt{n}} \right).$$

En reportant :

$$\varphi_n(\theta_n(x)) = n \left(1 + \frac{x}{\sqrt{n}} - 1 - \ln \left(1 + \frac{x}{\sqrt{n}} \right) \right) - \sqrt{n}x \ln \left(1 + \frac{x}{\sqrt{n}} \right).$$

Soit, avec $u = \frac{x}{\sqrt{n}}$:

$$\varphi_n = n(u - (1+u)\ln(1+u)).$$

0.2.3 Majoration explicite pour $x \geq 3$

On utilise l'inégalité classique $\ln(1+u) \geq \frac{2u}{2+u}$ pour $u > 0$ (elle se vérifie en étudiant la fonction $f(u) = \ln(1+u) - \frac{2u}{2+u}$, dont la dérivée est $\frac{u^2}{(1+u)(2+u)^2} \geq 0$ et $f(0) = 0$). Alors :

$$u - (1+u)\ln(1+u) \leq u - (1+u) \cdot \frac{2u}{2+u} = \frac{u(2+u) - 2u(1+u)}{2+u} = \frac{2u + u^2 - 2u - 2u^2}{2+u} = -\frac{u^2}{2+u}.$$

Donc :

$$\varphi_n \leq -n \cdot \frac{u^2}{2+u} = -\frac{x^2}{2+x/\sqrt{n}}.$$

Ainsi, pour $x \geq 3$ et $n \geq 1$:

$$\mathbb{P}(\bar{P}_n > x) \leq \exp \left(-\frac{x^2}{2+x/\sqrt{n}} \right) \leq \exp \left(-\frac{9}{2+3/\sqrt{n}} \right) \leq e^{-9/5} = e^{-1.8} \approx 0.165.$$

Pour $x = 3$, cette majoration est déjà petite. Pour $x > 3$, elle décroît exponentiellement vite. De plus, $1 - \Phi(3) \approx 0,0013$.

0.2.4 Cas $x < -3$

Par symétrie, on a $\mathbb{P}(\bar{P}_n < -3) = \mathbb{P}(P_n < n - 3\sqrt{n})$. On peut appliquer la même inégalité à $-P_n$ ou utiliser le fait que pour x négatif, on écrit $\mathbb{P}(\bar{P}_n < x) = \mathbb{P}(-\bar{P}_n > -x)$ et on utilise la même méthode (les calculs sont symétriques). On obtient la même borne.

Ainsi, pour $|x| > 3$, la quantité $|\mathbb{P}(\bar{P}_n \leq x) - \Phi(x)|$ est majorée par $0.165 + (1 - \Phi(3))$, et $1 - \Phi(3) \approx 0.0013$. L'erreur est donc inférieure à 0.17, mais surtout elle décroît très rapidement quand $|x|$ augmente. On peut donc restreindre l'étude à $x \in [-3, 3]$ sans perte significative pour l'évaluation de α_n .

0.2.5 Justification numérique de la restriction à $[-3, 3]$

Le souci avec la majoration explicite est qu'elle est assez lâche : elle donne une borne de l'ordre de 0,17 pour $x \geq 3$, ce qui ne permet pas d'estimer précisément α_n . De plus, cette approche ne fournit qu'une majoration théorique, pas une valeur effective de l'erreur.

Pour confirmer numériquement qu'on peut légitimement se limiter à $x \in [-3, 3]$, on calcule pour $n = 1000$ l'erreur maximale à l'intérieur et à l'extérieur de cet intervalle.

On obtient les résultats suivants :

- Erreur maximale dans $[-3, 3]$: 0,008409
- Erreur maximale hors de $[-3, 3]$: 0,000117
- Rapport : 1,39%




Figure 1: Erreur d'approximation pour $n = 1000$. Les pointillés verticaux représentent $x = -3$ et $x = 3$.

L'erreur hors de $[-3, 3]$ ne représente que 1,4% de l'erreur maximale. Elle est donc négligeable, ce qui valide la restriction à $[-3, 3]$ pour l'étude de α_n .

0.3 Calcul de α_n en $O(\sqrt{n})$ opérations

On cherche à évaluer :

$$\alpha_n = \sup_{x \in [-3, 3]} |F_n(x) - \Phi(x)|,$$

où $F_n(x) = \mathbb{P}(\bar{P}_n \leq x) = \mathbb{P}(P_n \leq n + \sqrt{nx})$.




Figure 2: Comparaison de la fonction de répartition de $\bar{P}_n$ (Poisson centrée-réduite) et de Φ (normale) pour $n = 100$.

0.3.1 Discrétisation adaptée

La fonction $x \mapsto F_n(x)$ est constante par morceaux, avec des sauts aux points $x_m = \frac{m-n}{\sqrt{n}}$ pour $m \in \mathbb{N}$. Le supremum de $|F_n(x) - \Phi(x)|$ sur $[-3, 3]$ est donc atteint en l'un de ces x_m .

On se restreint aux m tels que $x_m \in [-3, 3]$, c'est-à-dire :

$$\lceil n - 3\sqrt{n} \rceil \leq m \leq \lfloor n + 3\sqrt{n} \rfloor.$$

Le nombre de ces m est d'environ $6\sqrt{n} + 1$, soit $O(\sqrt{n})$.

0.3.2 Algorithme

Pour chaque m dans cet intervalle :

1. Calculer $F_n(x_m) = \mathbb{P}(P_n \leq m)$ (fonction de répartition de Poisson en m).
2. Calculer $\Phi(x_m)$ (fonction de répartition normale).
3. Évaluer la différence $|F_n(x_m) - \Phi(x_m)|$.

On prend le maximum de ces différences.

0.3.3 Complexité

Avec une bibliothèque numérique efficace (comme SciPy), le calcul de $\mathbb{P}(P_n \leq m)$ pour un m donné s'effectue en temps constant $O(1)$, de même que $\Phi(x_m)$. Le nombre de points à tester étant $O(\sqrt{n})$, la complexité totale est $O(\sqrt{n})$.

0.4 Vitesse de convergence de α_n

On cherche à déterminer si α_n tend vers 0 plus vite que $1/\sqrt{n}$.

Le théorème central limite assure que $F_n(x) \rightarrow \Phi(x)$ pour tout x , mais ne donne pas de vitesse. On veut savoir si la convergence est plus rapide que $1/\sqrt{n}$.

0.4.1 Minoration : $\alpha_n \geq c/\sqrt{n}$

On montre d'abord qu'on ne peut pas avoir mieux que $1/\sqrt{n}$. Pour $x = 1$, considérons $k = n + \sqrt{n}$. Par la formule de Stirling :

$$k! = \sqrt{2\pi k} \left(\frac{k}{e}\right)^k e^{\theta_k/(12k)}, \quad 0 < \theta_k < 1.$$

Alors :

$$p_k = e^{-n} \frac{n^k}{k!} = \frac{1}{\sqrt{2\pi k}} \exp\left(-n + k \ln n + k - k \ln k - \frac{\theta_k}{12k}\right).$$

On a $k \ln k = k \ln n + k \ln(1 + 1/\sqrt{n})$. En utilisant $\ln(1+u) = u - u^2/2 + u^3/3 + O(u^4)$ avec $u = 1/\sqrt{n}$, on obtient :

$$k \ln k = k \ln n + \sqrt{n} + \frac{1}{2} - \frac{1}{3\sqrt{n}} + O\left(\frac{1}{n}\right).$$

Alors $-n + k \ln n + k - k \ln k = -\frac{1}{2} + \frac{1}{3\sqrt{n}} + O(1/n)$. Ainsi :

$$p_k = \frac{1}{\sqrt{2\pi n}} e^{-1/2} \exp\left(\frac{1}{3\sqrt{n}} + O\left(\frac{1}{n}\right)\right) \left(1 + O\left(\frac{1}{\sqrt{n}}\right)\right).$$

Donc $p_k = \frac{e^{-1/2}}{\sqrt{2\pi n}} + o\left(\frac{1}{\sqrt{n}}\right)$.

La fonction de répartition F_n est constante sur l'intervalle $[x_{k-1}, x_k[$ où $x_{k-1} = \frac{(n+\sqrt{n}-1)-n}{\sqrt{n}} = 1 - \frac{1}{\sqrt{n}}$ et $x_k = 1$. Plus précisément :

$$F_n(x) = \mathbb{P}(P_n \leq n + \sqrt{n} - 1) \quad \text{pour } x \in [1 - 1/\sqrt{n}, 1[,$$

et $F_n(1) = \mathbb{P}(P_n \leq n + \sqrt{n}) = F_n(1^-) + p_k$.

Ainsi, F_n fait un saut de hauteur p_k au point $x = 1$:

$$F_n(1) - F_n(1^-) = p_k.$$

La fonction Φ est continue, donc $\Phi(1^-) = \Phi(1)$. Considérons la valeur de $|F_n(x) - \Phi(x)|$ juste avant le saut, en $x = 1 - \varepsilon$ avec $\varepsilon \rightarrow 0^+$:

$$|F_n(1^-) - \Phi(1)| = |(F_n(1) - p_k) - \Phi(1)|.$$

Par l'inégalité triangulaire :

$$|F_n(1) - \Phi(1)| \geq ||F_n(1^-) - \Phi(1)| - p_k|.$$

Mais on peut obtenir une borne plus simple : soit $|F_n(1^-) - \Phi(1)|$, soit $|F_n(1) - \Phi(1)|$ est au moins $p_k/2$. En effet, si $|F_n(1^-) - \Phi(1)| \geq p_k/2$, alors $\alpha_n \geq p_k/2$. Sinon, $|F_n(1^-) - \Phi(1)| < p_k/2$, et alors :

$$|F_n(1) - \Phi(1)| = |F_n(1^-) + p_k - \Phi(1)| \geq p_k - |F_n(1^-) - \Phi(1)| > p_k - p_k/2 = p_k/2.$$

Dans les deux cas, $\alpha_n \geq p_k/2$. Ainsi :

$$\alpha_n \geq \frac{1}{2}p_k = \frac{1}{2} \left(\frac{e^{-1/2}}{\sqrt{2\pi n}} + o\left(\frac{1}{\sqrt{n}}\right) \right) = \frac{e^{-1/2}}{2\sqrt{2\pi}} \cdot \frac{1}{\sqrt{n}} + o\left(\frac{1}{\sqrt{n}}\right).$$

On pose $c = \frac{e^{-1/2}}{2\sqrt{2\pi}} \approx 0,12$. Pour n assez grand, on a $\alpha_n \geq \frac{c}{\sqrt{n}}$.

0.4.2 Majoration $\alpha_n \leq C/\sqrt{n}$

On utilise la caractérisation suivante : pour deux variables aléatoires X et Y de fonctions de répartition F et G , on a :

$$\sup_x |F(x) - G(x)| = \frac{1}{2} \sup_{\|f\|_\infty \leq 1} |\mathbb{E}[f(X)] - \mathbb{E}[f(Y)]|,$$

où le supremum est pris sur les fonctions f bornées (ou lipschitziennes). On utilise ici des fonctions f de classe C^2 bornées ainsi que leurs dérivées.

Soit f une fonction C^2 telle que $\|f\|_\infty \leq 1$, $\|f'\|_\infty \leq 1$, $\|f''\|_\infty \leq 1$. On compare $\mathbb{E}[f(\bar{P}_n)]$ et $\mathbb{E}[f(Z)]$ où $Z \sim \mathcal{N}(0,1)$.

On écrit $\bar{P}_n = \frac{1}{\sqrt{n}} \sum_{i=1}^n (X_i - 1)$ avec $X_i \sim \text{Poisson}(1)$ indépendantes. Soit $Y_i = X_i - 1$, de moyenne nulle, variance 1, et $\mathbb{E}[|Y_i|^3] < \infty$.

Posons :

$$S_n^{(i)} = \frac{1}{\sqrt{n}} \left(\sum_{j=1}^{i-1} Z_j + \sum_{j=i+1}^n Y_j \right).$$

avec $Z_i \sim \mathcal{N}(0,1)$ indépendante.

Alors :

$$\mathbb{E}[f(\bar{P}_n)] - \mathbb{E}[f(Z)] = \sum_{i=1}^n \left(\mathbb{E} \left[f \left(S_n^{(i)} + \frac{Y_i}{\sqrt{n}} \right) \right] - \mathbb{E} \left[f \left(S_n^{(i)} + \frac{Z_i}{\sqrt{n}} \right) \right] \right).$$

Pour chaque terme, on développe f à l'ordre 2 :

$$f \left(S + \frac{Y}{\sqrt{n}} \right) = f(S) + \frac{Y}{\sqrt{n}} f'(S) + \frac{Y^2}{2n} f''(S) + \frac{Y^3}{6n^{3/2}} f'''(\xi).$$

En prenant l'espérance et en utilisant que $\mathbb{E}[Y_i] = 0$ et $\mathbb{E}[Y_i^2] = 1$, on a :

$$\mathbb{E} \left[f \left(S + \frac{Y_i}{\sqrt{n}} \right) \right] = \mathbb{E}[f(S)] + \frac{1}{2n} \mathbb{E}[f''(S)] + \frac{1}{6n^{3/2}} \mathbb{E}[Y_i^3 f'''(\xi)].$$

De même pour Z_i (gaussienne centrée réduite) : $\mathbb{E}[Z_i] = 0$, $\mathbb{E}[Z_i^2] = 1$, et $\mathbb{E}[Z_i^3] = 0$. Donc le terme d'ordre $1/n^{3/2}$ disparaît :

$$\mathbb{E} \left[f \left(S + \frac{Z_i}{\sqrt{n}} \right) \right] = \mathbb{E}[f(S)] + \frac{1}{2n} \mathbb{E}[f''(S)].$$

La différence est donc :

$$\left| \mathbb{E} \left[f \left(S + \frac{Y_i}{\sqrt{n}} \right) \right] - \mathbb{E} \left[f \left(S + \frac{Z_i}{\sqrt{n}} \right) \right] \right| \leq \frac{C}{n^{3/2}} \mathbb{E}[|Y_i|^3] \leq \frac{C'}{n^{3/2}}.$$

En sommant sur $i = 1$ à n , on obtient :

$$|\mathbb{E}[f(\bar{P}_n)] - \mathbb{E}[f(Z)]| \leq \frac{C''}{\sqrt{n}}.$$

Ceci étant vrai pour toute f C^2 bornée avec dérivées bornées, on en déduit (par approximation des indicatrices) que :

$$\alpha_n = \sup_x |F_n(x) - \Phi(x)| \leq \frac{C}{\sqrt{n}}.$$

La constante C peut être explicitée (par exemple $C = \mathbb{E}[|Y|^3]/\sqrt{2\pi}$), mais son existence suffit.




Figure 3: Convergence de α_n vers 0 en échelle log-log. La droite $1/\sqrt{n}$ est tracée en pointillés.




Figure 4: Le produit $\alpha_n \sqrt{n}$ tend vers une constante, confirmant que $\alpha_n \sim C/\sqrt{n}$.

0.4.3 Conclusion

On a établi :

$$\frac{c}{\sqrt{n}} \leq \alpha_n \leq \frac{C}{\sqrt{n}}$$

pour n assez grand. Donc $\alpha_n = \Theta(1/\sqrt{n})$, c'est-à-dire que α_n décroît exactement comme $1/\sqrt{n}$.

0.5 Estimation par simulation

On considère K réalisations indépendantes $X_{n,1}, \dots, X_{n,K} \sim \text{Poisson}(n)$. On définit :

$$\hat{p}_{n,x,K} = \frac{1}{K} \sum_{k=1}^K \mathbf{1}_{]-\infty, x]} \left(\frac{X_{n,k} - n}{\sqrt{n}} \right),$$

et l'erreur estimée :

$$\hat{\alpha}_{n,K} = \sup_{x \in \mathbb{R}} |\hat{p}_{n,x,K} - \Phi(x)|.$$

0.5.1 Décomposition de l'erreur

$$\hat{\alpha}_{n,K} \leq \underbrace{\sup_x |\hat{p}_{n,x,K} - F_n(x)|}_{\text{erreur d'estimation } E_{\text{est}}} + \underbrace{\sup_x |F_n(x) - \Phi(x)|}_{\text{erreur d'approximation } \alpha_n}.$$

0.5.2 Ordre de grandeur de K

On sait que $K\hat{p}_{n,x,K} \sim \text{Binomial}(K, F_n(x))$. Donc :

$$\mathbb{E}[\hat{p}_{n,x,K}] = F_n(x), \quad \text{Var}(\hat{p}_{n,x,K}) = \frac{F_n(x)(1 - F_n(x))}{K} \leq \frac{1}{4K}.$$

L'écart-type est donc en $1/\sqrt{K}$. Par l'inégalité de Tchebychev, pour tout $\varepsilon > 0$:

$$\mathbb{P}(|\hat{p}_{n,x,K} - F_n(x)| > \varepsilon) \leq \frac{1}{4K\varepsilon^2}.$$

L'écart-type de $\hat{p}_{n,x,K}$ est au plus $1/(2\sqrt{K})$. Ainsi, l'erreur d'estimation $|\hat{p}_{n,x,K} - F_n(x)|$ est typiquement de l'ordre de $1/\sqrt{K}$: pour une constante c fixée,

$$\mathbb{P}\left(|\hat{p}_{n,x,K} - F_n(x)| > \frac{c}{\sqrt{K}}\right) \leq \frac{1}{4c^2}.$$

En prenant c grand, on rend cette probabilité arbitrairement petite.

On a vu que $\alpha_n \sim C/\sqrt{n}$. Pour que l'erreur d'estimation soit négligeable devant α_n , il faut :

$$\frac{1}{\sqrt{K}} \ll \frac{1}{\sqrt{n}} \implies K \gg n.$$

En pratique, on peut prendre $K = n^2$ (ou $K = n^{1+\delta}$ avec $\delta > 0$). Avec ce choix, $1/\sqrt{K} = 1/n$ est négligeable devant $1/\sqrt{n}$.

0.5.3 Vérification de l'assertion

L'assertion est : $\hat{\alpha}_{n,K_n} \rightarrow 0$ plus vite que $n^{-1/2}$.

Avec $K_n \gg n$, l'erreur d'estimation est négligeable, donc $\hat{\alpha}_{n,K_n} \approx \alpha_n$. Or α_n est exactement d'ordre $1/\sqrt{n}$ (on a montré $\alpha_n \geq c/\sqrt{n}$). Donc $\hat{\alpha}_{n,K_n}$ se comporte comme $1/\sqrt{n}$: il ne tend pas plus vite que $1/\sqrt{n}$.

0.5.4 Problèmes rencontrés

- **Coût de calcul** : Pour $n = 10^4$, prendre $K = n^2 = 10^8$ nécessite de générer 10^8 variables de Poisson, ce qui est très lourd en temps et en mémoire.
- **Variance de l'estimateur** : L'erreur d'estimation en $1/\sqrt{K}$ est lente à décroître. Pour $K = 10^6$, l'erreur d'estimation est de l'ordre de 10^{-3} , ce qui est encore comparable à α_n pour $n = 10^6$.
- **Approximation du supremum** : En pratique, on ne peut pas tester tous les $x \in \mathbb{R}$. On se restreint à $x \in [-3, 3]$ et on discrétise. Cela introduit une erreur supplémentaire.




Figure 5: Estimation de α_n par simulation pour $n = 1000$ en fonction du nombre d'échantillons K . La ligne horizontale représente la valeur exacte $\alpha_n \approx 0,0084$.

0.6 Conclusion

La vitesse de convergence de α_n vers 0 est exactement $1/\sqrt{n}$ (on ne peut pas faire mieux). Pour observer cette vitesse par simulation, il faudrait $K \gg n$, ce qui est coûteux. En pratique, pour n grand, l'erreur d'estimation masque l'erreur d'approximation.